

Chapter 3

Clustering

Nội dung

- Tổng quan Clustering
- Quy trình xây dựng mô hình
- Các thuật toán cơ bản
- Đánh giá mô hình
- Cải thiện mô hình
- Bài tập ứng dụng

Clustering

- Định nghĩa: Clustering (phân cụm) là một bài toán trong học máy không giám sát (unsupervised learning), trong đó mục tiêu là phân chia tập dữ liệu thành các nhóm (clusters) sao cho:
 - Các điểm dữ liệu trong cùng một cụm thì giống nhau (theo một tiêu chí đo độ tương đồng/khoảng cách).
 - Các điểm dữ liệu khác cụm thì khác nhau nhiều.

- Input: tập dữ liệu chưa có nhãn (unlabeled data).
- Output: tập nhãn (cluster labels) được thuật toán gán ra, thường chỉ mang tính chất phân nhóm, không có ý nghĩa định danh sẵn.

Distance metric

- Khoảng cách Euclidean

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- Khoảng cách Manhattan

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$


- Khoảng cách Cosine (Cosine similarity)

$$d(x, y) = 1 - \frac{x \cdot y}{\|x\| \|y\|}$$

Ví dụ

- Tính khoảng cách 2 vị trí A(2,3) và B (5,7)
 - Khoảng cách Euclidean: 5
 - Khoảng cách Manhattan: 7
 - Khoảng cách Cosine: 0.0005

Clustering



Ứng dụng

- Phân cụm (tài liệu, khách hàng, dữ liệu,...)
- Phát hiện bất thường
- Hỗ trợ bài toán gán nhãn tự động
- Trích đặc trưng

Các thuật toán

- K-means
-
- Mạng Nơ ron RBF

Đánh giá

Đánh giá clustering khó hơn classification, vì dữ liệu clustering không có nhãn thật

Khi có nhãn thật để so sánh:

- Accuracy, Precision, Recall, F1-score: so sánh nhãn phân cụm với nhãn thật.
- Adjusted Rand Index (ARI): so sánh sự tương đồng giữa hai phân.

Không có nhãn thật:


- Vẽ dữ liệu 2D/3D để quan sát các cụm.
- Kết hợp các hàm đánh giá phân cụm

TRÍCH ĐẶC TRƯNG BẢNG MẠNG RBF (Radial Basis Function Network)


- Đặc trưng là những thông tin quan trọng, mang tính “đại diện” cho dữ liệu, giúp ta:
 - Phân biệt giữa các nhóm dữ liệu khác nhau.
 - Biểu diễn dữ liệu ban đầu ở dạng gọn và có ý nghĩa hơn.
 - Phục vụ cho các bước sau như phân loại, phát hiện lỗi, nén dữ liệu,...

Đặc trưng trong mạng RBF

- Trong mạng RBF (Radial Basis Function Network):
 - Mỗi neuron RBF có một center (tâm cụm) và sigma (độ rộng cụm).
 - Khi dữ liệu x đi qua mạng RBF, mỗi neuron sẽ tính giá trị ngõ ra $\phi_i(x)$
 - Kết quả là một **vector** $\phi(x) = [\phi_1(x), \phi_2(x), \dots, \phi_K(x)]$. Đây chính là **đặc trưng** mà mạng RBF sinh ra từ dữ liệu đầu vào.



- Ví dụ:



Huấn luyện mô hình

- Huấn luyện không giám sát (Unsupervised Feature Learning)
- Huấn luyện bán giám sát (Semi-supervised Feature Learning)
- Huấn luyện có giám sát (Supervised Feature Learning)

Hàm mục tiêu

- Riêng phần đặc trưng, không dùng cross-entropy như phân loại có nhãn, mà dùng các thành phần sau:
 - Variance loss: ép các điểm gần 1 center → gom cụm.
 - Separation loss: các center phải cách xa nhau.
 - Sigma loss: sigma thích nghi theo phân bố → tránh quá lớn hoặc quá nhỏ.



Thank you!

ĐẠI HỌC CÔNG NGHIỆP THÀNH PHỐ HỒ CHÍ MINH

CS Chính: 12 Nguyễn Văn Bảo, Phường 4, Quận Gò Vấp, TP.HCM | ĐT: 0283.8940 390 | Fax: 0283.9940 954

PH Quảng Ngãi: 938 Quang Trung, TP. Quảng Ngãi, Tỉnh Quảng Ngãi | ĐT: 0255.625.0075 | Fax: 0255.371. 3858

CS Thanh Hóa: Phường Quảng Tâm, TP.Thanh Hóa, Tỉnh Thanh Hóa | ĐT: 0237.367.5092 | Fax: 0237.367.5350